

Міністерство освіти і науки України

Харківський національний університет радіоелектроніки

Факультет _____ Комп'ютерних Наук _____
(повна назва)

Кафедра _____ Програмної інженерії _____
(повна назва)

КОМПЛЕКСНИЙ КУРСОВИЙ ПРОЄКТ

Пояснювальна записка

рівень вищої освіти _____ другий (магістерський) _____

Дослідження методів автоматичної обробки текстової інформації для створення
корпусів української мови
(тема)

Виконав:

Студент 2 курсу, групи _____ ІПЗм-24-3 _____

Панченко К.А.

(прізвище, ініціали)

Спеціальність 121 – Інженерія програмного

Забезпечення

(код і повна назва спеціальності)

Тип програми _____ освітньо-наукова _____

Освітня програма _____ Інженерія

програмного

забезпечення

(повна назва освітньої програми)

Керівник _____ доц. Валенда Н.А.

(посада, прізвище, ініціали)

Члени комісії:

проф. Шубін І.Ю.

(посада, прізвище, ініціали)

доц. Назаров О.С.

(посада, прізвище, ініціали)

доц. Голян Н.В.

(посада, прізвище, ініціали)

Харківський національний університет радіоелектроніки

Факультет _____ Комп'ютерних Наук _____
Кафедра _____ Програмної інженерії _____
Рівень вищої освіти _____ другий (магістерський) _____
Спеціальність _____ 121 – Інженерія програмного забезпечення _____
(код і повна назва)
Тип програми _____ освітньо-наукова _____
Освітня програма _____ Інженерія програмного забезпечення _____
(повна назва)

Курс 2 Група ІПЗм-24-3 Семестр 1

ЗАВДАННЯ
на курсовий проєкт(роботу) студента

Панченко Кіріл Андрійович

(прізвище, ім'я, по батькові)

1. Тема роботи: «Дослідження методів автоматичної обробки текстової інформації для створення корпусів української мови»
2. Термін здачі студентом закінченої роботи 31 грудня 2025 р.
3. Вихідні дані до роботи: електронні ресурси та наукові публікації за тематикою Natural Language Processing (NLP) та корпусної лінгвістики, вимоги до структури та якості сучасних лінгвістичних корпусів, документація API месенджера Telegram (MTProto), мова програмування Python, середовище розробки PyCharm, система управління базами даних MongoDB, бібліотеки для обробки даних (Telethon, spaCy, scikit-learn, BeautifulSoup).
4. Перелік питань, що потрібно опрацювати в роботі: вступ та обґрунтування актуальності, аналіз предметної галузі та існуючих рішень, огляд літературних джерел, постановка задачі, теоретичне дослідження моделей векторизації та верифікації текстів, розробка алгоритмів обробки даних та архітектури програмного забезпечення, висновки, перелік посилань.

КАЛЕНДАРНИЙ ПЛАН

№	Назва етапів роботи	Термін	Відмітки про виконання
1	Аналіз предметної галузі	15.09.2025 – 15.10.2025	виконано
2	Огляд й аналіз літературних, наукових джерел	16.10.2025 – 31.10.2025	виконано
3	Постановка задачі	01.11.2025 – 07.11.2025	виконано
4	Теоретичне дослідження	08.11.2025 – 10.12.2025	виконано
5	Підготовка пояснювальної записки.	11.12.2025 – 22.12.2025	виконано
6	Перевірка на наявність ознак академічного плагіату	27.12.2025	виконано
7	Захист роботи	03.01.2026	виконано

Дата видачі завдання «10» _____ вересня _____ 2025 р.

Студент _____  _____ Панченко К.А.
(підпис)

Керівник роботи _____ доц. Валенда Н.А.
(підпис) (посада, прізвище, ініціали)

РЕФЕРАТ / ABSTRACT

Пояснювальна записка містить: 47 стор., 3 рис., 1 табл., 21 джерело.

АВТОМАТИЧНА ОБРОБКА ТЕКСТУ, ВЕРИФІКАЦІЯ, КОРПУСНА ЛІНГВІСТИКА, МЕТОДИ NLP, TELEGRAM, PYTHON, TF-IDF, COSINE SIMILARITY, MONGODB.

Об'єктом дослідження є процеси автоматизованої обробки, аналізу та структурування великих масивів текстової інформації природною мовою.

Предметом дослідження виступають методи та алгоритми автоматичної побудови текстових корпусів, зокрема методи визначення семантичної подібності (Semantic Textual Similarity) для верифікації достовірності інформації з неструктурованих джерел.

Метою роботи є дослідження методів автоматичної обробки текстової інформації та розробка програмного забезпечення для створення актуального, верифікованого корпусу української мови на основі даних соціальних мереж (Telegram) та авторитетних новинних ресурсів.

Методи розробки базуються на використанні мови програмування Python та її екосистеми для Data Science (бібліотеки scikit-learn, pandas). Для збору даних використовуються методи веб-скрапінгу та роботи з API (Telethon, BeautifulSoup), для лінгвістичної обробки — бібліотека spaCy, а для зберігання даних — документо-орієнтована СУБД MongoDB.

У результаті роботи були проаналізовані існуючі підходи до створення корпусів, розроблено алгоритми попередньої обробки та очищення текстів, а також запропоновано та реалізовано метод автоматичної верифікації новин на основі косинусної міри подібності векторів TF-IDF.

AUTOMATED TEXT PROCESSING, VERIFICATION, CORPUS LINGUISTICS, NLP METHODS, TELEGRAM, PYTHON, TF-IDF, COSINE SIMILARITY, MONGODB.

The object of research is the processes of automated processing, analysis, and structuring of large arrays of text information in natural language.

The subject of the study is the methods and algorithms for automatic construction of text corpora, in particular, methods for determining semantic textual similarity (STS) for verifying the reliability of information from unstructured sources.

The aim of the work is to study methods of automatic text processing and develop software for creating an up-to-date, verified corpus of the Ukrainian language based on data from social networks (Telegram) and authoritative news resources.

The development methods are based on the use of the Python programming language and its ecosystem for Data Science (scikit-learn, pandas libraries). Web scraping methods and API interaction (Telethon, BeautifulSoup) are used for data collection, the spaCy library for linguistic processing, and the document-oriented DBMS MongoDB for data storage.

As a result of the work, existing approaches to corpus creation were analyzed, algorithms for text preprocessing and cleaning were developed, and a method for automatic news verification based on the cosine similarity of TF-IDF vectors was proposed and implemented.

Я, Панченко Кіріл Андрійович, студент гр. ІПЗм-24-3, здобувач вищої освіти на другому (магістерському) рівні кафедри «Програмна інженерія», заявляю: мій комплексний курсовий проєкт на тему «Дослідження методів автоматичної обробки текстової інформації для створення корпусів української мови», що буде представлений для публічного захисту, виконаний самостійно, не містить елементи плагіату і може бути опублікований в електронному архіві з відкритим доступом ElArKhNURE. Всі запозичення з друкованих та електронних джерел мають відповідні посилання.

Я ознайомлений(на) з діючим положенням «Про протидію академічному плагіату в ХНУРЕ», відповідно до якого виявлення плагіату є підставою для відмови в допуску роботи до захисту та застосування дисциплінарних заходів.

ЗМІСТ

Вступ.....	9
1 Аналіз предметної галузі	12
1.1 Аналіз проблемної галузі дослідження.....	12
1.2 Огляд існуючих підходів та обмежень	13
1.3 Тенденції та перспективи розвитку.....	16
2 Огляд й аналіз літературних, наукових джерел	18
2.1 Огляд літературних джерел	18
2.2 Аналіз літератури	19
2.3 Оцінка актуальності та новизни	21
2.4 Висновки з огляду	22
3 Постановка задачі.....	24
4 Теоретичне дослідження	27
4.1 Математичні моделі представлення та порівняння текстів.....	27
4.2 Алгоритмічні аспекти попередньої обробки даних (nlp pipeline).....	29
4.3 Розробка методу автоматичної верифікації	31
4.3.1 Формування пошукового простору (time window filtering).....	31
4.3.2 Визначення найкращого відповідника (best match retrieval)	31
4.3.3 Прийняття рішення (thresholding)	32
4.4 Проектування архітектури програмного забезпечення.....	33
Висновки	36
Перелік джерел посилання	38
Перелік джерел посилання за науковими напрямками керівника та науковців кафедри програмної інженерії.	41
Додаток А Слайди презентації.....	42

ПЕРЕЛІК УМОВНИХ СКОРОЧЕНЬ

API – Application Programming Interface

БД – База даних

ГРАК – Генеральний регіонально-анотований корпус української мови

ПЗ – Програмне забезпечення

СУБД – Система управління базами даних

BERT – Bidirectional Encoder Representations from Transformers

BSON – Binary JSON

HTML – HyperText Markup Language

HTTP – HyperText Transfer Protocol

JSON – JavaScript Object Notation

LLM – Large Language Model

MTProto – Mobile Telegram Protocol

NER – Named Entity Recognition

NLP – Natural Language Processing

POS – Part-Of-Speech

RoBERTa – Robustly optimized BERT approach

STS – Semantic Textual Similarity

TF-IDF – Term Frequency-Inverse Document Frequency

URL – Uniform Resource Locator

ВСТУП

У сучасному світі інформаційних технологій стрімкий розвиток штучного інтелекту, зокрема великих мовних моделей (LLM), докорінно змінив підходи до обробки природної мови (Natural Language Processing, NLP). Якість роботи таких систем критично залежить від наявності великих, репрезентативних та якісно розмічених текстових даних. Для української мови, яка в контексті світових досліджень часто класифікується як мова з обмеженими ресурсами (low-resource language), проблема створення актуальних навчальних корпусів стоїть особливо гостро.

Одним із ключових етапів створення сучасних лінгвістичних ресурсів є автоматизований збір та обробка текстової інформації з відкритих джерел. Традиційні методи ручного формування корпусів не здатні задовольнити потреби сучасних алгоритмів через низьку швидкість та високу вартість. Тому на перший план виходять методи автоматичної агрегації даних із соціальних мереж та месенджерів, які є джерелом «живої» мови, неологізмів та реакцій на актуальні події.

Актуальність теми дослідження полягає в необхідності удосконалення методів автоматичної побудови корпусів української мови, які б забезпечували не лише обсяг даних, але і їхню достовірність. Існуючі корпуси часто є статичними та застарілими, а автоматичний збір даних (web scraping) без належної верифікації призводить до накопичення «шуму», дублікатів та дезінформації. Особливо це стосується даних з месенджера Telegram, який, з одного боку, є цінним джерелом оперативної інформації, а з іншого – характеризується низьким рівнем фактологічного контролю.

Метою роботи є дослідження методів автоматичної обробки текстової інформації та розробка програмного забезпечення для створення актуального, верифікованого корпусу української мови на основі даних соціальних мереж (Telegram) та авторитетних новинних ресурсів.

Для досягнення цієї мети необхідно вирішити наступні завдання:

- провести аналіз існуючих методів автоматичної обробки текстової інформації (NLP), які застосовуються для побудови корпусів (токенізація, лематизація, векторизація);
- дослідити алгоритми визначення семантичної подібності текстів та їх застосовність для задач автоматичної верифікації контенту;
- розробити архітектуру системи, що включатиме модулі збору даних, лінгвістичної обробки та верифікації;
- реалізувати програмні засоби для автоматичного збору неструктурованих даних з Telegram-каналів та еталонних даних з перевірених новинних сайтів;
- розробити та програмно реалізувати алгоритм, який автоматично порівнює повідомлення з Telegram зі статтями на новинних сайтах для визначення їх статусу (правдива/непідтверджена);
- провести експериментальне дослідження ефективності розроблених методів, оцінити точність алгоритму верифікації та якість створеного корпусу.

Об'єктом дослідження є процеси автоматизованої обробки, аналізу та структурування великих масивів текстової інформації природною мовою.

Предметом дослідження виступають методи та алгоритми автоматичної побудови текстових корпусів, зокрема методи визначення семантичної подібності (Semantic Textual Similarity) для верифікації достовірності інформації з неструктурованих джерел.

Методи дослідження базуються на використанні мови програмування Python та її екосистеми для Data Science. Для збору даних використовуються методи веб-скрапінгу та роботи з API (бібліотеки Telethon, BeautifulSoup). Для лінгвістичної обробки (токенізація, лематизація, NER) застосовується бібліотека spaCy. Для векторизації текстів та обчислення їх подібності використовуються методи TF-IDF та косинусної міри (Cosine Similarity) з бібліотеки scikit-learn. Зберігання даних реалізовано за допомогою документо-орієнтованої СУБД MongoDB.

Наукова новизна роботи полягає у розробці удосконаленого методу формування текстового корпусу, який, на відміну від існуючих підходів «сліпого» збору, інтегрує етап автоматичної фактологічної верифікації контенту з Telegram-каналів шляхом їх семантичного порівняння з еталонними джерелами. Це дозволяє автоматично маркувати ступінь достовірності даних у корпусі, підвищуючи його якість для задач машинного навчання.

Практичне значення отриманих результатів полягає у створенні програмного інструментарію, що дозволяє автоматизувати процес збору якісних мовних даних українською мовою. Сформований корпус та розроблене ПЗ можуть бути використані для покращення українських NLP-моделей, систем моніторингу інформаційного простору та виявлення дезінформації.

1 АНАЛІЗ ПРЕДМЕТНОЇ ГАЛУЗІ

1.1 Аналіз проблемної галузі дослідження

В епоху стрімкого розвитку штучного інтелекту та технологій обробки природної мови (Natural Language Processing, NLP) ключовим ресурсом, що визначає якість кінцевих моделей, стають дані. Ефективність сучасних великих мовних моделей (LLM) та алгоритмів машинного навчання безпосередньо залежить від наявності великих, репрезентативних та, що найважливіше, якісно розмічених текстових корпусів. Для української мови, яка в світовому контексті NLP все ще класифікується як мова з обмеженими ресурсами (low-resource language), проблема створення та наповнення актуальних корпусів залишається критичною [3]. Незважаючи на значний прогрес останніх років, кількість та якість доступних датасетів для української мови все ще значно поступається ресурсам для англійської чи інших європейських мов, що створює технологічний бар'єр для розвитку вітчизняних інтелектуальних систем.

Традиційні лінгвістичні корпуси, що створювалися вручну експертами-лінгвістами, протягом тривалого часу слугували еталоном якості. Проте в умовах експоненційного зростання обсягів інформації вони не можуть задовольнити потреби сучасних систем через обмежений обсяг та низьку швидкість оновлення. Існуючі анотовані набори даних для української мови часто є тематично обмеженими або специфічними, що не дозволяє ефективно використовувати їх для навчання моделей широкого профілю [2]. Це спонукає дослідників звертатися до методів автоматичного збору даних (web scraping) з відкритих джерел інтернету, що дозволяє швидко накопичувати великі масиви тексту.

Особливе місце серед джерел текстових даних займають соціальні мережі та месенджери, серед яких в українському сегменті інтернету домінує Telegram. Ця платформа є унікальним джерелом «живої» мови, що містить неологізми, сленг, специфічну військову лексику та миттєві реакції соціуму на актуальні події, які часто відсутні в академічних текстах чи художній літературі [7]. Такий матеріал є безцінним для навчання моделей, які мають розуміти сучасний контекст та розмовну мову.

Проте використання даних із соціальних мереж пов'язане з низкою серйозних викликів. По-перше, такі тексти характеризуються високим рівнем шуму: вони містять граматичні помилки, нестандартну пунктуацію, суржик та емодзі, що ускладнює їх автоматичну обробку. По-друге, в умовах інформаційної війни критичною проблемою стає поширення неперевіреної інформації, чуток та свідомої дезінформації [9]. Наповнення навчальних корпусів таким контентом без попередньої фільтрації створює ризик, відомий як "garbage in, garbage out": моделі, навчені на недостовірних даних, будуть генерувати галюцинації або поширювати фейки.

Таким чином, проблемна область дослідження охоплює не лише технічні аспекти автоматичного збору та очищення текстів, але й складну задачу забезпечення їхньої фактологічної якості. Створення корпусу «сліпим» методом автоматичного парсингу призводить до накопичення токсичного та маніпулятивного контенту. Це актуалізує потребу в розробці нових методів, які б інтегрували процедури верифікації безпосередньо в процес створення корпусу.

1.2 Огляд існуючих підходів та обмежень

На сьогодні для української мови існує кілька значних корпусних проєктів, які використовуються як стандарти в галузі комп'ютерної лінгвістики. Найвідомішими та найбільш цитованими серед них є Генеральний регіонально-анотований корпус української мови (ГРАК) та корпус UberText.

Генеральний регіонально-анотований корпус української мови (ГРАК) є одним з найбільш репрезентативних академічних ресурсів. Він охоплює тексти з XIX по XXI століття, містить детальну метарозмітку та дозволяє досліджувати регіональні особливості мови. ГРАК є незамінним інструментом для лінгвістичних досліджень [2], проте його основним обмеженням у контексті навчання NLP-моделей є орієнтація на літературні, публіцистичні та наукові тексти, що проходять певний редакційний відбір. Процес наповнення та оновлення таких корпусів є досить повільним, що не дозволяє відслідковувати динамічні мовні зміни в режимі реального часу.

UberText, у свою чергу, являє собою масштабний корпус, зібраний переважно з новинних стрічок та онлайн-видань. Завдяки своєму обсягу та сучасній лексиці він краще підходить для задач NLP [1]. Проте, як зазначають дослідники, навіть такі корпуси мають обмеження щодо покриття специфічних доменів та жанрів, а також можуть містити застарілу лексику, яка не повною мірою відображає сучасний стан мовного ужитку, що швидко змінюється під впливом соціально-політичних факторів.

Для наочного порівняння характеристик існуючих рішень та запропонованої системи, зведемо основні параметри до таблиці 1.1. Як видно з наведених даних, ключовою відмінністю розроблюваної системи є орієнтація на динамічний контент із соціальних мереж та наявність вбудованого модуля автоматичної верифікації достовірності.

Таблиця 1.1 – Порівняльна характеристика підходів до формування корпусів української мови

Характеристика	ГРАК (General Regionally Annotated Corpus)	UberText (Lang-uk)	Розроблювана система (Telegram-News Corpus)
Джерела даних	Художні, публіцистичні та наукові тексти (XIX–XXI ст.)	Новинні стрічки, онлайн-видання, сайти	Telegram-канали (соціальні мережі) та перевірені новинні сайти
Тип лексики	Літературна, нормативна, академічна	Офіційно-ділова, публіцистична	«Жива» розмовна мова, сленг, неологізми, військова лексика
Динамічність	Статичний (оновлюється рідко, вручну/напівавтоматично)	Статичний (фіксує стан мови на момент збору)	Динамічний (збір та оновлення у режимі реального часу)
Верифікація фактів	Забезпечується редакційним відбором джерел	Відсутня («сліпий» веб-скрапінг)	Автоматизована (Semantic Textual Similarity з еталонними джерелами)

Продовження таблиці 1.1

Характеристика	ГРАК (General Regionally Annotated Corpus)	UberText (Lang-uk)	Розроблювана система (Telegram-News Corpus)
Основний недолік	Повільне оновлення, відсутність оперативної лексики	Наявність «шуму» та застарілої інформації, відсутність перевірки на фейки	Необхідність складної попередньої обробки неструктурованого тексту

Процес автоматичного створення корпусів з веб-джерел зазвичай реалізується через стандартизований пайплайн. Він розпочинається з автоматичного обходу вебсторінок (web crawling) за заданими правилами або списком доменів. Наступним кроком є очищення контенту (boilerplate removal), яке передбачає відокремлення основного тексту статті від навігаційних елементів, реклами, HTML-тегів та службової інформації. Після цього застосовуються алгоритми дедуплікації для видалення повних або часткових копій текстів, а також фільтрація за мовою (language detection), щоб відсіяти іншомовний контент.

Головним недоліком існуючих підходів до формування корпусів із соціальних медіа є відсутність етапу фактологічної верифікації. При роботі з даними з платформ на кшталт Telegram, Twitter/X чи Facebook, традиційні методи скрапінгу збирають увесь доступний контент, що відповідає мовним критеріям, не розрізняючи достовірні новини від суб'єктивних думок, чуток чи цілеспрямованих маніпуляцій [4]. Це призводить до того, що значна частина зібраного корпусу може складатися з інформаційного сміття.

Існуючі інструменти для автоматичного виявлення фейкових новин (Fake News Detection) часто базуються на складних моделях глибокого навчання, що аналізують стиль тексту або патерни поширення інформації. Однак такі методи вимагають великих, експертно розмічених навчальних вибірок (labeled datasets) із прикладами фейків та правдивих новин, яких для української мови критично бракує [10]. Це створює замкнене коло: для створення якісного детектору фейків

потрібен розмічений корпус, а для створення чистого корпусу потрібен надійний детектор фейків.

Отже, існує нагальна науково-практична потреба в розробці альтернативних методів фільтрації, які б дозволяли автоматично верифікувати зібрані дані без необхідності у великих розмічених навчальних наборах. Перспективним напрямком є використання порівняння з довіреними джерелами (Reference-based Fact Checking), де достовірність тексту з соціальної мережі визначається через його семантичну відповідність матеріалам авторитетних новинних агентств.

1.3 Тенденції та перспективи розвитку

Сучасний розвиток технологій обробки природної мови демонструє чітку зміну парадигми: наукова спільнота поступово відходить від екстенсивного шляху, що базувався на гонитві за кількісними показниками обсягу даних, до інтенсивного, де пріоритетом стає їхня якість, чистота та надійності. Аналіз останніх досліджень у сфері комп'ютерної лінгвістики дозволяє стверджувати, що майбутнє корпусних технологій лежить у площині створення інтелектуальних систем, здатних не просто агрегувати текст, а й здійснювати його глибоку семантичну фільтрацію.

Однією з ключових тенденцій є інтеграція методів автоматичної перевірки фактів (Fact-Checking) безпосередньо у архітектуру систем збору даних. Якщо раніше верифікація розглядалася як окрема задача, що вирішується постфактум, то сьогодні дослідники пропонують вбудовувати модулі оцінки достовірності на ранніх етапах пайплайну. Найбільш перспективним інструментом для цього стає метод семантичної подібності текстів (Semantic Textual Similarity, STS). Він дозволяє порівнювати неструктуровані повідомлення із соціальних мереж з надійними джерелами інформації, визначаючи ступінь їхньої змістової тотожності, а не просто лексичного збігу [6]. Такий підхід дозволяє автоматизувати процес відділення фактів від фейків без залучення людських ресурсів.

Паралельно відбувається активне впровадження гібридних підходів до аналізу тексту, що поєднують класичні статистичні методи з новітніми

нейромережевими архітектурами. Досвід показує, що використання перевірених часом алгоритмів, таких як TF-IDF, у тандемі з сучасними векторними представленнями слів (Word Embeddings) або трансформерними моделями (BERT, RoBERTa), дозволяє досягти оптимального балансу між швидкістю обробки та точністю результатів. Цей симбіоз є особливо ефективним при роботі з різнорідними даними, дозволяючи системі розуміти контекст повідомлень, написаних різними стилями, що є типовим для середовища Telegram [4].

Ще одним важливим вектором розвитку є перехід до концепції динамічних корпусів. Статичні набори даних, які фіксують стан мови на певний момент часу, швидко втрачають свою актуальність в умовах сучасного інформаційного потоку. Натомість виникає потреба у створенні "живих" корпусів, які оновлюються в режимі реального часу. Це стає критично важливим для моніторингу інформаційного простору під час кризових ситуацій, зокрема війни, коли швидкість появи нових термінів, наративів та загроз дезінформації вимагає миттєвої реакції.

Окремої уваги заслуговує зростаючий фокус світової науки на підтримці мов з обмеженими ресурсами (low-resource languages)[3], до яких належить і українська. Розробка методів крос-мовної верифікації та адаптація багатомовних моделей відкриває нові можливості для українських дослідників. Це дозволяє використовувати глобальний досвід для вирішення локальних задач, зокрема створення спеціалізованих верифікованих корпусів, які стануть фундаментом для побудови безпечних та етичних національних систем штучного інтелекту [1].

Таким чином, перспективи розвитку предметної області пов'язані зі створенням автоматизованих систем, які виступатимуть не пасивними архіварами, а активними інтелектуальними фільтрами. Реалізація таких систем дозволить вирішити проблему інформаційного шуму та забезпечить дослідників якісними даними, необхідними для подальшого прогресу в галузі штучного інтелекту.

2 ОГЛЯД Й АНАЛІЗ ЛІТЕРАТУРНИХ, НАУКОВИХ ДЖЕРЕЛ

2.1 Огляд літературних джерел

У межах дослідження методів автоматичної побудови та верифікації корпусів української мови було проведено системний пошук та аналіз наукових публікацій. Метою огляду було виявлення сучасних підходів (State-of-the-Art) у сферах комп'ютерної лінгвістики, обробки природної мови (NLP) та автоматичної перевірки фактів (Automated Fact-Checking).

Для формування джерельної бази використовувалися провідні наукометричні платформи та цифрові бібліотеки: Google Scholar, ACL Anthology (Association for Computational Linguistics), IEEE Xplore, arXiv.org та ResearchGate. Пошук здійснювався за ключовими словами українською та англійською мовами: «NLP corpus creation», «low-resource languages», «Ukrainian language corpus», «automated fact-checking», «Telegram fake news detection», «semantic textual similarity».

Критерії відбору джерел включали:

- актуальність: пріоритет надавався роботам, опублікованим у період з 2019 по 2024 роки, оскільки галузь NLP розвивається надзвичайно стрімко (зокрема, з появою трансформерних моделей);
- релевантність: відбиралися дослідження, що стосуються специфіки української мови або методів роботи з неструктурованими даними соціальних мереж;
- наукова значущість: Враховувалися публікації у рецензованих журналах та матеріалах профільних конференцій (UNLP, LREC-COLING, EMNLP).

За результатами пошуку відібрані джерела були класифіковані за трьома тематичними групами.

Перша група - розробка та наповнення текстових корпусів. У цю групу увійшли фундаментальні роботи, що описують існуючі корпуси української мови та методологію їх створення. Особливу увагу приділено публікаціям Дмитра Чаплинського щодо корпусу UberText 2.0 (2023), який є стандартом для навчання сучасних мовних моделей [1], а також роботам Марії Шведової та співавторів щодо розвитку Генерального регіонально-анотованого корпусу української мови (ГРАК)

[2]. Також проаналізовано дослідження, що розглядають українську мову в контексті *low-resource languages* (мов з обмеженими ресурсами) та пропонують методи подолання дефіциту даних, наприклад, робота Haltiuk та ін. (2024) про шляхи перетворення української на мову з високими ресурсами [3].

Друга група - виявлення дезінформації та аналіз даних у Telegram. Ця група джерел висвітлює специфіку роботи з даними месенджерів. Важливими є матеріали воркшопів UNLP (Ukrainian Natural Language Processing Workshop), зокрема спільні задачі (Shared Tasks) 2024–2025 років, присвячені виявленню маніпуляцій та пропаганди в українському сегменті Telegram [4]. Роботи таких авторів, як Ustyianovych та Barbosa (2024), надають розуміння технічних підходів до класифікації текстів у Telegram-каналах та виявлення патернів поширення фейків.

Остання група - методи автоматичної перевірки фактів (Automated Fact-Checking). Третя група охоплює теоретичні та практичні роботи з автоматизації фактчекінгу. Сюди увійшли оглядові статті (surveys), наприклад, робота Guo et al. (2022) та Akhtar et al. (2023), які систематизують методи визначення правдивості на основі NLP [5]. Особливий інтерес становлять дослідження, що пропонують використання методів семантичної подібності (Semantic Textual Similarity) та трансформерних моделей (BERT, RoBERTa) для порівняння тверджень (claims) з доказами (evidence) [6].

Таким чином, сформована джерельна база охоплює як фундаментальні питання корпусної лінгвістики, так і прикладні аспекти боротьби з дезінформацією, що створює надійне підґрунтя для розробки власної системи верифікації.

2.2 Аналіз літератури

Аналіз відібраних джерел дозволяє глибше зрозуміти еволюцію методів обробки текстової інформації та виявити ключові тенденції у створенні мовних ресурсів для української мови. Дослідження у першій групі, присвяченій корпусній лінгвістиці, демонструють значний прогрес у подоланні дефіциту даних. Робота Дмитра Чаплинського, присвячена корпусу UberText 2.0 [1], є фундаментальною для розуміння сучасних підходів до масового збору даних (web crawling). Автор

детально описує методологію очищення текстів від «сміття» (boilerplate removal) та дедуплікації, що дозволило зібрати понад 3 мільярди токенів. Однак, аналіз показує, що основний акцент у цій роботі зроблено на лінгвістичній чистоті та обсязі, тоді як фактологічна достовірність контенту залишається поза межами автоматизованої перевірки. Це підтверджує тезу про те, що існуючі методики створення корпусів орієнтовані на форму, а не на зміст.

Паралельно, дослідження Марії Шведової та колег щодо корпусу ГРАК [2] ілюструють академічний підхід до анотації, де кожному тексту присвоюються детальні метадані, включаючи регіон походження та жанр. Хоча такий підхід забезпечує високу якість даних, він є трудомістким і складно масштабується для задач реального часу, таких як моніторинг новинних стрічок у месенджерах. Робота Haliuk та ін. [3] пропонує стратегії трансформації української мови з категорії low-resource у high-resource, наголошуючи на важливості використання автоматизованих пайплайнів та трансферного навчання (transfer learning) від багатших на ресурси мов.

Друга група джерел, що фокусується на аналізі Telegram, розкриває специфічні виклики роботи з цим середовищем. Матеріали воркшопів UNLP, зокрема результати спільних задач із виявлення маніпуляцій [4], свідчать про те, що тексти у Telegram мають унікальні характеристики: вони коротші, емоційно забарвлені та часто містять неявну пропаганду. Дослідники активно використовують трансформерні моделі (BERT, RoBERTa) для класифікації таких повідомлень. Проте більшість розглянутих робіт зосереджені на бінарній класифікації (фейк/правда) або виявленні мови ворожнечі на основі внутрішніх ознак тексту, без порівняння з зовнішніми джерелами. Це обмежує їхню ефективність у випадках, коли фейк написаний нейтральним стилем і виглядає як звичайна новина.

Третій напрямок досліджень – автоматична перевірка фактів – пропонує рішення, яке може компенсувати недоліки попередніх підходів. Оглядова робота Guo et al. [5] систематизує методи fact-checking і виділяє підхід на основі пошуку доказів (evidence retrieval) як найбільш перспективний. Суть методу полягає у

розбитті процесу на три етапи: виявлення твердження, пошук відповідних документів у базі знань та визначення вердикту. Дослідження FacTeR-Check [6] розвиває цю ідею, пропонуючи використовувати семантичну подібність (Semantic Textual Similarity) для зіставлення перевіряємих тверджень із заголовками авторитетних новин. Такий підхід дозволяє верифікувати інформацію не через аналіз стилю, а через перевірку наявності підтвердження у надійних джерелах.

Узагальнюючи аналіз літератури, можна стверджувати, що на сьогодні існують ефективні інструменти для збору даних (як в UberText) та потужні методи семантичного аналізу (як у Fact-Checking системах). Однак, інтеграція цих двох компонентів у єдину систему для автоматичного створення верифікованих корпусів української мови залишається недостатньо дослідженою. Більшість існуючих рішень вирішують ці задачі окремо, що відкриває простір для наукового пошуку в напрямку створення гібридних систем, які поєднують масовий збір даних із їхньою миттєвою семантичною верифікацією.

2.3 Оцінка актуальності та новизни

Проведений огляд та аналіз літературних джерел підтверджують беззаперечну актуальність дослідження в сфері створення верифікованих корпусів української мови. В умовах гібридної війни та інформаційного протистояння, український сегмент інтернету, і зокрема месенджер Telegram, перенасичений дезінформацією та маніпулятивним контентом. Існуючі підходи до створення корпусів, як-от UberText [1], хоча й вирішують проблему обсягу даних, не мають вбудованих механізмів перевірки правдивості. Це створює ризик використання «отруєних» даних (data poisoning) при навчанні національних моделей штучного інтелекту.

Аналіз літератури виявив суттєву прогалину: більшість методів детекції фейків [4] покладаються на класифікацію стилю тексту, що є недостатнім для виявлення якісно написаних фейків або рерайтів. Водночас, методи автоматичного фактчекінгу [5] розвиваються переважно для англійської мови і рідко застосовуються для задач масового збору даних у реальному часі.

Новизна нашого дослідження полягає у розробці гібридного підходу, який поєднує методи масового збору неструктурованих даних (web scraping) з методами автоматичної верифікації на основі семантичного порівняння з довіреними джерелами. На відміну від існуючих рішень, які аналізують текст ізольовано, ми пропонуємо використовувати метод Reference-based Verification, де кожне повідомлення з Telegram перевіряється на відповідність контенту авторитетних новинних ресурсів.

Інноваційним аспектом є застосування технік Semantic Textual Similarity (STS) та метрик косинусної подібності для автоматичного маркування ступеня довіри до кожного елемента корпусу. Це дозволяє перетворити процес створення корпусу з простого накопичення текстів на інтелектуальну селекцію фактів. Такий підхід не лише покращує якість самого корпусу, але й створює фундамент для розробки автономних систем моніторингу інформаційного простору, здатних працювати без постійного втручання людини-фактчекера.

Практична цінність роботи підсилюється орієнтацією на українську мову як low-resource language [3]. Запропонований метод дозволяє автоматично генерувати розмічені dataset'и (пари «фейк-спростування» або «твердження-підтвердження»), які є критично необхідними для навчання наступних поколінь українських NLP-моделей.

2.4 Висновки з огляду

Проведена оцінка літературних джерел підтверджує, що обраний напрямок дослідження знаходиться на вістрі сучасної комп'ютерної лінгвістики. Аналіз показав, що хоча інструментарій для збору даних (scrapers) та інструментарій для аналізу тексту (NLP models) розвинені достатньо добре, їх ефективна комбінація для задачі верифікації корпусів української мови ще не реалізована повною мірою.

Ключові висновки з огляду літератури:

- дефіцит якісних даних: існуючі корпуси (ГРАК, UberText) є статичними і не покривають динамічний контент месенджерів;

- обмеженість методів: традиційні методи виявлення фейків вимагають великих розмічених вибірок, яких для української мови бракує;
- перспективність STS: методи семантичної подібності є найбільш адекватним інструментом для автоматичної верифікації без попереднього навчання на розмічених даних.

Таким чином, огляд літератури обґрунтовує доцільність розробки програмної системи, яка б автоматизувала процес збору даних з Telegram та їх верифікацію через порівняння з новинними сайтами. Це дозволить закрити існуючу наукову прогалину та створити інструмент, затребуваний як дослідниками даних, так і фахівцями з інформаційної безпеки.

3 ПОСТАНОВКА ЗАДАЧІ

Після аналізу предметної галузі та виявлення ключових проблем, пов'язаних зі створенням корпусів української мови, було визначено необхідність розробки нових підходів, які б поєднували автоматичний збір даних із їхньою фактологічною верифікацією. Аналіз літературних джерел показав, що існуючі рішення або фокусуються виключно на обсязі даних, ігноруючи їхню якість, або використовують складні моделі для детекції фейків, які потребують розмічених навчальних вибірок, відсутніх для української мови.

Метою роботи є розробка програмного забезпечення для автоматизованого створення верифікованого корпусу української мови, що базується на семантичному порівнянні неструктурованих повідомлень із Telegram-каналів з еталонними даними авторитетних новинних ресурсів.

Основна науково-технічна проблема полягає у неможливості використання стандартних методів веб-скрапінгу для наповнення якісних лінгвістичних корпусів через високий рівень інформаційного шуму та дезінформації в соціальних мережах. Поставлена задача передбачає створення системи, здатної в автоматичному режимі виконувати повний цикл обробки інформації: від збору "сирих" даних до їх очищення, лінгвістичної нормалізації та верифікації.

Для досягнення поставленої мети необхідно вирішити ряд технічних завдань:

- розробка модуля збору даних (Data Collection) – реалізація асинхронного механізму отримання повідомлень з Telegram-каналів у реальному часі та парсингу новинних вебсайтів для формування еталонної бази знань;
- розробка модуля попередньої обробки (Preprocessing) – створення алгоритмів очищення тексту від специфічного шуму месенджерів (емодзі, гіперпосилань, хештегів) та лінгвістичної нормалізації (токенізація, лематизація) для приведення текстів до вигляду, придатного для математичного аналізу;
- реалізація алгоритму верифікації – розробка методу визначення семантичної подібності текстів на основі векторних представлень (TF-

IDF) та косинусної міри (Cosine Similarity), що дозволить автоматично визначати ступінь відповідності повідомлення з Telegram перевіреним новинам;

- проєктування схеми зберігання даних – розробка структури бази даних, яка дозволить ефективно зберігати як оригінальні тексти, так і метадані про їхню достовірність, джерело походження та час публікації.

Для формалізації функціональних вимог до розроблюваного програмного забезпечення та визначення меж системи було побудовано діаграму варіантів використання (Use Case Diagram). Вона відображає основні сценарії взаємодії користувача (дослідника) та автоматизованих процесів із компонентами системи. Взаємодію акторів та прецедентів наведено на рис. 3.1.




Рисунок 3.1 – Діаграма варіантів використання системи

Обґрунтування вибору інструментів реалізації базується на вимогах до швидкодії обробки текстів та гнучкості роботи з неструктурованими даними. В якості основної мови програмування обрано Python через наявність потужної екосистеми бібліотек для Data Science (scikit-learn, pandas) [14] та обробки природної мови (spaCy) [15]. Для взаємодії з Telegram API буде використано

бібліотеку Telethon[17], яка підтримує асинхронну роботу, що критично важливо для обробки великих потоків повідомлень.

Для зберігання даних обрано документо-орієнтовану СУБД MongoDB [16]. На відміну від реляційних баз даних, MongoDB дозволяє зберігати JSON-подібні документи (BSON) зі змінною структурою, що ідеально підходить для різномірних даних із соціальних мереж, які можуть містити різний набір полів (текст, зображення, метадані пересилань).

Після реалізації програмного забезпечення необхідно створити тестове середовище для проведення експериментального дослідження. Воно включатиме вибірку з кількох тисяч повідомлень із популярних українських новинних Telegram-каналів та відповідний пул новин з перевірених сайтів (наприклад, «Українська правда», «Суспільне»).

Для оцінки ефективності розробленого методу будуть використані стандартні метрики задач класифікації та інформаційного пошуку:

- Precision (точність) – покаже, яка частка новин, позначених системою як «верифіковані», дійсно є правдивими;
- Recall (повнота) – покаже, яку частку правдивих новин система змогла знайти та підтвердити серед усього масиву даних;
- F1-Score – це гармонічне середнє між точністю та повнотою, що дозволить оцінити загальний баланс алгоритму;
- час обробки – це середній час, необхідний для верифікації одного повідомлення, що є критичним параметром для систем, які працюють у режимі, наближеному до реального часу.

Очікувані результати включають створення діючого програмного прототипу, який дозволить автоматично формувати корпус текстів із розміткою достовірності. Це вирішить проблему наповнення українських лінгвістичних баз актуальними даними та надасть дослідникам інструмент для швидкої фільтрації інформаційного простору.

4 ТЕОРЕТИЧНЕ ДОСЛІДЖЕННЯ

4.1 Математичні моделі представлення та порівняння текстів

Ключовим етапом роботи системи автоматичної верифікації новин є перетворення текстової інформації, яка за своєю природою є неструктурованою, у числовий вигляд, придатний для математичного аналізу. Цей процес називається векторизацією. Для вирішення задачі порівняння новин з Telegram та офіційних джерел було обрано модель "мішка слів" (Bag of Words) з використанням зважування TF-IDF (Term Frequency-Inverse Document Frequency) [19].

Вибір методу TF-IDF зумовлений кількома факторами:

- інтерпретованість: на відміну від "чорних скриньок" глибокого навчання (deep learning embeddings), результати TF-IDF легко пояснити: ми точно знаємо, які слова вплинули на схожість текстів;
- обчислювальна ефективність: метод не потребує потужних графічних процесорів (GPU) для навчання та інференсу, що дозволяє системі працювати в режимі реального часу навіть на звичайному серверному обладнанні;
- стійкість до шуму: при правильному налаштуванні (видалення рідкісних слів) TF-IDF ефективно фільтрує "сміттєві" слова, характерні для соціальних мереж.

Нехай $D = \{d_1, d_2, \dots, d_N\}$ – множина документів (новин) у нашому корпусі. Словник корпусу V складається з усіх унікальних слів (термінів), що зустрічаються в документах. Кожен документ d_j представляється як вектор у багатовимірному просторі розмірністю $|V|$:

$$\vec{d_j} = (w_{1,j}, w_{2,j}, \dots, w_{|V|,j})$$

де $w_{i,j}$ – вага i -го терміна (t_i) в документі d_j .

Вага $w_{i,j}$ обчислюється як добуток двох компонентів:

$$w_{i,j} = TF(t_i, d_j) \times IDF(t_i, D)$$

Term Frequency (TF) визначає частоту терміна в конкретному документі. Вона показує, наскільки слово важливе для опису змісту саме цього тексту. Для уникнення зміщення в бік довгих текстів використовується нормована частота:

$$TF(t_i, d_j) = \frac{n_{i,j}}{\sum_k n_{k,j}}$$

де $n_{i,j}$ – кількість входжень терміна t_i в документ d_j , а знаменник – загальна кількість слів у документі.

Inverse Document Frequency (IDF) оцінює загальну важливість слова для всього корпусу. Вона зменшує вагу слів, які зустрічаються занадто часто (наприклад, загальновживані слова "рік", "сьогодні", "Україна") і не несуть унікальної інформації для розрізнення документів.

$$IDF(t_i, D) = \log\left(\frac{|D|}{|\{d \in D: t_i \in d\}|}\right)$$

де $|D|$ – загальна кількість документів у корпусі, а знаменник – кількість документів, що містять термін t_i .

Таким чином, найбільшу вагу отримують слова, які часто зустрічаються в конкретній новині, але рідко – в інших новинах корпусу. Це дозволяє виділити унікальні ключові слова (наприклад, прізвища, географічні назви, специфічні терміни), що описують подію.

Після перетворення текстів у вектори виникає задача визначення ступеня їхньої семантичної близькості. Для цього використовується косинусна міра подібності. На відміну від евклідової відстані, яка залежить від довжини векторів (а отже, від довжини текстів), косинусна міра оцінює кут між векторами [20]. Це критично важливо, оскільки новина в Telegram може бути коротким повідомленням, а стаття на сайті – розгорнутим аналітичним матеріалом, але вони описують одну й ту ж подію.

Коефіцієнт подібності $Sim(\vec{A}, \vec{B})$ між вектором новини з Telegram ($\vec{A}$) та вектором новини з перевіреного джерела ($\vec{B}$) обчислюється за формулою:

$$Sim(\vec{A}, \vec{B}) = \cos(\theta) = \frac{\vec{A} \cdot \vec{B}}{\|\vec{A}\| \cdot \|\vec{B}\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}}$$

Результат набуває значень у діапазоні $[0,1]$ (оскільки елементи векторів TF-IDF невід'ємні):

- 1: вектори колінеарні, тексти ідентичні або складаються з однакових ключових слів;
- 0: вектори ортогональні, тексти не мають спільних значущих слів.

У розробленій системі цей показник використовується для прийняття рішення про верифікацію: якщо максимальне значення подібності між новиною з Telegram та будь-якою новиною з бази `trusted_news` перевищує встановлений поріг τ (threshold), новина вважається підтвердженою.

4.2 Алгоритмічні аспекти попередньої обробки даних (NLP Pipeline)

Оскільки вхідні дані з Telegram характеризуються високим рівнем «шуму» (емодзі, сленг, специфічна пунктуація, посилання, рекламні інтеграції), критично важливим етапом є попередня обробка тексту (Data Preprocessing). Без якісного очищення та нормалізації математичні моделі (такі як TF-IDF) не зможуть коректно сформувати вектори, що призведе до значного розрідження матриці ознак та зниження точності верифікації. Розроблений конвеєр обробки даних (NLP pipeline) реалізовано мовою Python з використанням бібліотек `re` та `sre` та складається з кількох послідовних етапів.

Першим кроком є нормалізація тексту (Text Normalization). Цей етап передбачає зведення тексту до канонічного вигляду, що є фундаментом для подальшої обробки. Зокрема, виконується Unicode Normalization (форма NFC), що гарантує ідентичність байтових кодів для візуально однакових символів, усуваючи проблему дублювання термінів через різне кодування. Також застосовується Case Folding – приведення всіх символів до нижнього регістру, що дозволяє алгоритму ідентифікувати слова, написані в різному регістрі, як один і той самий токен.

Наступним етапом є очищення від «шуму» (Noise Removal). Специфіка Telegram-каналів полягає у великій кількості службових елементів, які не несуть семантичного навантаження для задачі фактчекінгу. За допомогою регулярних виразів (Regular Expressions) з тексту видаляються URL-посилання, які часто є рекламними, теги користувачів (@username), службові команди, емодзі та спецсимволи. Також усуваються залишки Markdown-розмітки, що використовуються для форматування в месенджері. Це дозволяє очистити текст від елементів, які можуть заважати роботі статистичних моделей.

Далі виконується токенизація (Tokenization) – процес розбиття тексту на окремі атомарні одиниці (токени). Для української мови це є нетривіальною задачею через наявність апострофів. Використання стандартних розділювачів може призвести до помилкового розбиття слів. Тому в системі застосовується спеціалізований токенизатор бібліотеки spaCy (модель uk_core_news_sm), налаштований на правила української орфографії, що забезпечує коректне виділення слів.

Критично важливим етапом для зменшення розмірності векторного простору є лематизація (Lemmatization). Це процес зведення слова до його початкової, словникової форми – леми. Оскільки українська мова є флективною, слова активно змінюються за відмінками, родами, числами та часами. Без лематизації різні форми одного слова (наприклад, *«президент», «президента», «президентом»*) створювали б окремі виміри у векторі TF-IDF. Зведення їх до єдиної леми дозволяє алгоритму коректно враховувати частоту терміна незалежно від його граматичної форми, суттєво підвищуючи щільність інформації та якість роботи метрики косинусної подібності.

Завершальним етапом є фільтрація стоп-слів (Stop-word Removal). Цей процес передбачає видалення слів, що мають високу частоту в мові, але низьку інформативну цінність. До них належать загальномовні стоп-слова (прийменники, сполучники, частки) та доменно-специфічні слова, характерні для новинних Telegram-каналів (наприклад, *«підпишись», «посилання», «канал»*). Їх видалення дозволяє сфокусувати увагу алгоритму на суті новини та зменшити розмір

словника корпусу на 30-40% без втрати змістовної інформації, що позитивно впливає на швидкодію та точність системи верифікації.

4.3 Розробка методу автоматичної верифікації

Основним функціональним елементом системи є модуль верифікації, який класифікує новини з Telegram на «підтверджені» та «непідтверджені». Цей процес базується на гіпотезі, що правдива резонансна подія, описана в соціальних мережах, з високою ймовірністю буде висвітлена авторитетними новинними агентствами протягом короткого проміжку часу.

Метод верифікації реалізовано як послідовний алгоритм, що складається з декількох кроків.

4.3.1 Формування пошукового простору (Time Window Filtering)

Пряме порівняння кожного повідомлення з Telegram з усіма новинами в базі даних *trusted_news* є обчислювально неефективним, оскільки база постійно зростає. Для оптимізації швидкодії застосовується фільтрація за часовим вікном.

Нехай T_{tg} – час публікації повідомлення в Telegram. Для перевірки відбирається підмножина новин-кандидатів $D_{candidates}$ з довірених джерел, час публікації яких T_{news} потрапляє в інтервал:

$$D_{candidates} = \{d \in D_{trusted} \mid T_{tg} - \Delta t \leq T_d \leq T_{tg} + \Delta t\}$$

де Δt – параметр часового вікна (наприклад, 24 години). Це дозволяє врахувати ситуації, коли новина в Telegram з'являється раніше за офіційну публікацію (оперативність месенджерів) або з невеликим запізненням.

4.3.2 Визначення найкращого відповідника (Best Match Retrieval)

Для вектора новини з Telegram $\vec{V}_{tg}$ та множини векторів-кандидатів $\{\vec{V}_1, \vec{V}_2, \dots, \vec{V}_k\}$ з $D_{candidates}$ обчислюється косинусна подібність. Метою є знаходження новини-еталона, яка максимізує функцію подібності:

$$Score_{max} = \max_{d_i \in D_{candidates}} (\text{Sim}(\vec{V}_{tg}, \vec{V}_{d_i}))$$

4.3.3 Прийняття рішення (Thresholding)

Фінальний вердикт щодо статусу повідомлення виноситься на основі порівняння максимальної оцінки схожості $Score_{max}$ із заздалегідь визначеним пороговим значенням τ (threshold). Це значення визначається емпіричним шляхом (наприклад, $\tau = 0.6$) для мінімізації помилок першого та другого роду.

Функція верифікації $Verify(d_{tg})$ визначається як:

$$Verify(d_{tg}) = \begin{cases} \text{Verified,} & \text{якщо } Score_{max} \geq \tau \\ \text{Unverified,} & \text{якщо } Score_{max} < \tau \end{cases}$$

Якщо новина отримує статус Verified, система зберігає посилання на знайдене першоджерело, що дозволяє користувачеві побачити підтвердження інформації. Статус Unverified означає, що в авторитетних джерелах не знайдено семантично схожих публікацій у заданому часовому проміжку, що може свідчити про фейк, суб'єктивну думку автора каналу або занадто локальну подію.




Рисунок 4.1 – Блок-схема алгоритму семантичної верифікації повідомлень

Алгоритмічна реалізація методу, наведена на рис. 4.1, складається з трьох етапів. На першому етапі відбувається оптимізація пошукового простору через фільтрацію за часовим вікном (Time Window Filtering). На другому етапі виконується розрахунок семантичної близькості (Cosine Similarity) для відібраних кандидатів. На фінальному етапі система порівнює максимальний отриманий бал із пороговим значенням τ для прийняття бінарного рішення щодо верифікації.

4.4 Проектування архітектури програмного забезпечення

Для реалізації розроблених алгоритмів було спроектовано модульну архітектуру системи, яка базується на принципах слабкої зв'язності (low coupling) компонентів. Такий підхід дозволяє незалежно розробляти, тестувати та масштабувати окремі частини системи, забезпечуючи гнучкість при зміні джерел даних або вдосконаленні алгоритмів верифікації без впливу на загальну структуру.

Архітектура системи ієрархічно розділена на чотири основні рівні: рівень збору даних (Data Collection Layer), рівень обробки даних (Data Processing Layer), рівень зберігання (Data Storage Layer) та рівень аналізу і верифікації (Analysis & Verification Layer). Така сегрегація відповідальності дозволяє чітко розмежувати етапи життєвого циклу даних від моменту їх отримання до фінальної класифікації.




Рисунок 4.2 – Архітектура системи автоматичної верифікації контенту

Розроблена архітектура, представлена на рис. 4.2, забезпечує конвеєрну обробку інформації. Модулі збору даних (Scrapers) наповнюють базу MongoDB через проміжний етап NLP-обробки. Модуль верифікації аналізує збережені повідомлення, використовуючи векторизацію TF-IDF та метрику косинусної подібності для визначення їхнього статусу.

На рівні збору даних функціонують два ключові компоненти, що працюють паралельно. Перший – це Telegram Scraper, реалізований на базі асинхронної бібліотеки Telethon. Він виконує авторизацію через протокол MTProto, що дозволяє емулювати дії реального користувача, моніторити визначений список каналів та завантажувати нові повідомлення в режимі реального часу з мінімальною затримкою. Другим компонентом є Web Crawler, який використовує бібліотеки Requests та BeautifulSoup [18] для періодичного обходу сайтів довірених новинних агентств. Його задача – вилучення заголовків, основного тексту новин та метаданих для формування актуальної еталонної бази знань, з якою будуть порівнюватися повідомлення з месенджерів.

Рівень обробки даних виступає проміжною ланкою, де відбувається трансформація «сирих» даних у структурований формат. Центральним елементом тут є модуль Preprocessor, який реалізує NLP-пайплайн, детально описаний у попередніх підрозділах. Він відповідає за очищення тексту від специфічного шуму (емодзі, посилань), токенізацію, лематизацію та фільтрацію стоп-слів. Саме на цьому етапі неструктурований текст перетворюється на нормалізований набір лем, придатний для математичного моделювання.

Для рівня зберігання даних обрано документо-орієнтовану СУБД MongoDB, яка оптимально підходить для роботи з JSON-подібними структурами даних соціальних мереж. База даних організована у вигляді двох основних колекцій: telegram_posts та trusted_news. Перша колекція зберігає оригінальні повідомлення з Telegram разом з їхніми лематизованими версіями, метаданими (дата, канал, кількість переглядів) та результатами верифікації. Друга колекція містить перевірені новини з офіційних джерел, які слугують еталоном для порівняння.

Ядром системи є рівень аналізу та верифікації, де імплементовано математичні моделі TF-IDF та косинусної подібності. Модуль Vectorizer відповідає за перетворення текстових даних у векторний простір, тоді як модуль Verifier виконує пошук семантично схожих новин у межах визначеного часового вікна. Саме тут приймається рішення про присвоєння новині статусу Verified або Unverified на основі порогового значення подібності.

Взаємодія компонентів відбувається за чітко визначеним сценарієм: Telegram Scraper отримує нове повідомлення та передає його в Preprocessor. Після очищення текст зберігається в базі даних, що ініціює процес верифікації. Verifier запитує з бази даних релевантні новини з довірених джерел, проводить порівняльний аналіз і оновлює запис у базі даних, додаючи результат перевірки. Така архітектура забезпечує високу швидкість та надійність системи, дозволяючи обробляти великі потоки інформації в автоматичному режимі.

ВИСНОВКИ

У ході виконання курсового проєкту було вирішено актуальну науково-практичну задачу розробки програмного забезпечення для автоматизованого створення та верифікації корпусів української мови на основі даних соціальних мереж.

За результатами проведеного дослідження можна зробити наступні висновки:

- проаналізовано стан предметної області та встановлено, що існуючі корпуси української мови (ГРАК, UberText) є переважно статичними та не забезпечують достатнього покриття оперативної лексики з соціальних мереж. Виявлено, що основною перешкодою для використання даних з месенджера Telegram є високий рівень інформаційного шуму та низька фактологічна достовірність контенту;
- розроблено метод автоматичної верифікації повідомлень, який базується на порівнянні неструктурованих текстів із Telegram з еталонними новинами авторитетних ЗМІ. В основу методу покладено математичні моделі TF-IDF та косинусної міри подібності (Cosine Similarity), що дозволило реалізувати ефективний механізм семантичного зіставлення текстів без необхідності у великих розмічених навчальних вибірках;
- спроектовано модульну архітектуру програмної системи, яка складається з чотирьох рівнів: збору, попередньої обробки, зберігання та аналізу даних. Використання принципу слабкої зв'язності компонентів забезпечує гнучкість системи та можливість її подальшого масштабування;
- програмно реалізовано ключові компоненти системи мовою Python з використанням бібліотек Telethon (для асинхронної роботи з Telegram API) та BeautifulSoup (для парсингу новинних сайтів). Для лінгвістичної обробки (токенізація, лематизація, очищення від шуму) застосовано інструментарій бібліотеки spaCy, а для зберігання даних – документо-орієнтовану СУБД MongoDB;

- розроблено алгоритм прийняття рішень, який включає попередню фільтрацію за часовим вікном (Time Window Filtering) для оптимізації пошуку та порогову перевірку коефіцієнта подібності. Це дозволило автоматизувати процес маркування даних статусами «Verified»/«Unverified», перетворюючи «сирий» потік повідомлень на структурований корпус.

Практичне значення отриманих результатів полягає у створенні інструментарію, що дозволяє формувати якісні динамічні корпуси «живої» української мови. Розроблена система може бути використана для покращення NLP-моделей, моніторингу інформаційного простору та протидії дезінформації.

Перспективи подальшого розвитку роботи полягають у впровадженні більш складних методів векторизації на основі трансформерних моделей (наприклад, BERT) для підвищення точності семантичного аналізу та розробці веб-інтерфейсу для візуалізації результатів верифікації.

ПЕРЕЛІК ДЖЕРЕЛ ПОСИЛАННЯ

1. D. Chaplynskyi, “Introducing UberText 2.0: A Corpus of Modern Ukrainian at Scale,” *Proceedings of the Second Ukrainian Natural Language Processing Workshop (UNLP)*, Dubrovnik, Croatia, 2023, pp. 1–10. URL: <https://aclanthology.org/2023.unlp-1.1.pdf> (дата звернення: 10.12.2025).
2. M. Shvedova *et al.*, “Regional Annotation within GRAC, a Large Reference Corpus of Ukrainian: Issues and Challenges,” *Proceedings of the GRAC Workshop*, 2021. URL: <https://ceur-ws.org/Vol-2870/paper4.pdf> (дата звернення: 12.12.2025).
3. M. Haliuk and A. Smywiński-Pohl, “On the Path to Make Ukrainian a High-Resource Language,” *Proceedings of the Third Ukrainian Natural Language Processing Workshop (UNLP) @ LREC-COLING 2024*, Torino, Italy, 2024, pp. 120–128.
4. “Detecting Manipulation in Ukrainian Telegram: A Transformer-Based Approach,” *Proceedings of the Ukrainian Natural Language Processing Workshop*, 2025. URL: <https://aclanthology.org/2025.unlp-1.20.pdf> (дата звернення: 15.12.2025).
5. Z. Guo *et al.*, “A Survey on Automated Fact-Checking,” *Transactions of the Association for Computational Linguistics*, vol. 10, 2022, pp. 178–206.
6. “FacTeR-Check: Semi-Automated Fact-Checking through Semantic Similarity and Natural Language Inference,” ResearchGate, 2022. URL: <https://www.researchgate.net/publication/361424009> (дата звернення: 14.12.2025).
7. “Design and Construction of a Social Media Corpus: Influencers’ Speech in Vlogs,” *Research in Corpus Linguistics*, 2022. URL: <https://ricl.aelinco.es/index.php/ricl/article/view/304/260> (дата звернення: 13.12.2025).
8. N. Hassan *et al.*, “Automated Fact Checking: Task Formulations, Methods and Future Directions,” *Proceedings of the 27th International Conference on Computational Linguistics (COLING)*, 2018. URL: <https://aclanthology.org/C18-1283/> (дата звернення: 11.12.2025).
9. “Characterizing and Detecting Propaganda-Spreading Accounts on Telegram,” *arXiv preprint*, 2024. URL: <https://arxiv.org/html/2406.08084v1> (дата звернення: 16.12.2025).

10. “Enhancing Named Entity Recognition for Low-Resource Languages Using Large Language Models: A Ukrainian Case Study,” 2025. URL: <https://apps.ucu.edu.ua/wp-content/uploads/2025/06/ii.pdf> (дата звернення: 18.12.2025).
11. O. Smelyakov *et al.*, “Cross-Lingual Named Entity Recognition for the Ukrainian Language Based on Word Alignment,” *IEEE Xplore*, 2023. URL: <https://ieeexplore.ieee.org/document/10024219/> (дата звернення: 19.12.2025).
12. “Leveraging AI for Effective Fake News Detection and Verification,” *Arab Media & Society*, 2024. URL: <https://www.arabmediasociety.com/leveraging-ai-for-effective-fake-news-detection-and-verification/> (дата звернення: 17.12.2025).
13. “How Can Text Content Security Counter the Spread of Fake News?” Tencent Cloud Techpedia, 2023. URL: <https://www.tencentcloud.com/techpedia/122133> (дата звернення: 20.12.2025).
14. F. Pedregosa *et al.*, “Scikit-learn: Machine Learning in Python,” *Journal of Machine Learning Research*, vol. 12, 2011, pp. 2825–2830.
15. M. Honnibal and I. Montani, “spaCy 2: Natural Language Understanding with Bloom Embeddings, Convolutional Neural Networks and Incremental Parsing,” *Proceedings of the 2017 EMNLP Workshop: System Demonstrations*, 2017.
16. K. Chodorow, *MongoDB: The Definitive Guide*. O’Reilly Media, 2013, 432 p.
17. Telethon Documentation, 2024. URL: <https://docs.telethon.dev/en/stable/> (дата звернення: 18.12.2025).
18. Beautiful Soup Documentation, 2024. URL: <https://www.crummy.com/software/BeautifulSoup/bs4/doc/> (дата звернення: 18.12.2025).
19. “Text Clustering with TF-IDF in Python,” Medium, 2023. URL: <https://medium.com/@cmukesh8688/tf-idf-vectorizer-scikit-learn-dbc0244a911a> (дата звернення: 19.12.2025).

20. “Cosine Similarity – Understanding the Math and How It Works,” Machine Learning Plus, 2023. URL: <https://www.machinelearningplus.com/nlp/cosine-similarity/> (дата звернення: 19.12.2025).

21. V. Vysotska, A. Chupryna, N. Valenda, O. Konduforov “Evaluating the in-context learning capabilities of large language models for misinformation detection for Ukrainian news”, CIAW-2025, Lviv. URL: <https://ceur-ws.org/Vol-4110/paper15.pdf>. (дата звернення: 16.12.2025).

**ПЕРЕЛІК ДЖЕРЕЛ ПОСИЛАННЯ ЗА НАУКОВИМИ НАПРЯМАМИ
КЕРІВНИКА ТА НАУКОВЦІВ КАФЕДРИ ПРОГРАМНОЇ ІНЖЕНЕРІЇ.**

11. O. Smelyakov *et al.*, “Cross-Lingual Named Entity Recognition for the Ukrainian Language Based on Word Alignment,” *IEEE Xplore*, 2023. URL: <https://ieeexplore.ieee.org/document/10024219/> (дата звернення: 19.12.2025).

21. V. Vysotska, A. Chupryna, N. Valenda, O. Konduforov “Evaluating the in-context learning capabilities of large language models for misinformation detection for Ukrainian news”, CIAW-2025, Lviv. URL: <https://ceur-ws.org/Vol-4110/paper15.pdf>. (дата звернення: 16.12.2025).

ДОДАТОК А

Слайди презентації

Міністерство освіти і науки України
Харківський національний університет радіоелектроніки
Комплексний курсовий проєкт

Дослідження методів автоматичної обробки текстової інформації для
створення корпусів української мови

Виконав: ст. гр. ІПЗм-24-3 Панченко К.А.

Науковий керівник: доц. кафедри ПІ Валенда Н.А.

Мета та об'єкт дослідження

Об'єкт дослідження

Процеси автоматизованої обробки, аналізу та структурування великих масивів текстової інформації природною мовою в умовах швидкозмінного інформаційного середовища

Предмет дослідження

Методи та алгоритми автоматичної побудови текстових корпусів, зокрема методи визначення семантичної подібності (Semantic Textual Similarity) для верифікації достовірності контенту

Мета роботи

Дослідження методів автоматичної обробки та розробка програмного забезпечення для створення актуального, верифікованого корпусу української мови на основі даних Telegram та перевірених новинних ресурсів

Аналіз предметної галузі

Проблематика low-resource мов

Українська мова належить до категорії *low-resource languages* – мов із обмеженою кількістю цифрових ресурсів для навчання систем штучного інтелекту та обробки природної мови.

Статичність існуючих корпусів

Корпуси ГРАК та UberText рідко оновлюються, не відображають сучасних мовних трендів, неологізмів та актуальної лексики цифрової епохи

Академічність та формальність

Переважає літературна та офіційно-ділова мова, недостатня представленість розмовного стилю, сленгу та живої комунікації соціальних мереж

Відсутність верифікації

Ризик потрапляння неперевіреної інформації, фейків та маніпулятивного контенту без механізмів автоматичної перевірки достовірності

Потенціал Telegram: Месенджер є джерелом оперативної інформації, містить сучасну лексику та неологізми, але потребує ретельної фільтрації через високий рівень інформаційного шуму та дезінформації

03

Огляд літературних джерел

Методологія дослідження

Бази даних:

- Google Scholar
- ACL Anthology
- IEEE Xplore
- arXiv.org

Критерії відбору публікацій:

- Актуальність (2019–2025)
- Релевантність (NLP, українська мова)
- Наукова значущість та цитованість

Ключові напрямки аналізу

01

Методологія створення корпусів

Аналіз підходів UberText 2.0 та інших великомасштабних проєктів збору текстових даних

02

Виявлення маніпуляцій у Telegram

Дослідження результатів UNLP Shared Tasks з детекції пропаганди та дезінформації

03

Автоматичний Fact-Checking

Методи семантичної подібності для верифікації фактичної інформації

04

Постановка задачі

Створення системи автоматизованого збору, очищення та верифікації текстових даних для формування динамічного корпусу української мови

- 1** **Модуль збору даних**
Розробка автоматизованих скраперів для отримання контенту з Telegram-каналів та перевірених новинних веб-сайтів з підтримкою регулярного оновлення
- 2** **NLP-препроцесинг**
Реалізація багатетапного конвеєра обробки: очищення від шуму, токенизація, лематизація, видалення стоп-слів та нормалізація тексту
- 3** **Алгоритм верифікації**
Розробка методу автоматичної перевірки достовірності на основі порівняння семантичної подібності з першоджерелами
- 4** **Проектування бази даних**
Створення ефективної архітектури зберігання для верифікованого корпусу з підтримкою швидкого пошуку та аналітики

05

Інструментарій дослідження



Мова програмування

Python 3.9+ – основна мова розробки завдяки потужній екосистемі бібліотек для обробки природної мови та аналізу даних



Збір даних

Telethon для роботи з Telegram API, **BeautifulSoup** та **Scrapy** для витягування контенту з новинних веб-сайтів



NLP обробка

spaCy для токенизації та лематизації української мови, **scikit-learn** для векторизації (TF-IDF) та обчислення косинусної подібності



База даних

MongoDB – документо-орієнтована NoSQL СУБД з підтримкою формату BSON для гнучкого зберігання неструктурованих текстових даних

06

Теоретичне дослідження

Математична модель верифікації

Векторизація тексту (TF-IDF)

Перетворення текстового документа на числовий вектор, де вага кожного слова залежить від його частоти в документі та унікальності в усьому корпусі:

$$w_{i,j} = TF_{i,j} \times IDF_i$$

$$IDF_i = \log \frac{N}{df_i}$$

де N – кількість документів, df_i – кількість документів зі словом i

Косинусна подібність

Визначення семантичної близькості двох текстів через обчислення кута між їх векторними представленнями:

$$Sim(\vec{A}, \vec{B}) = \cos(\theta) = \frac{\vec{A} \cdot \vec{B}}{||\vec{A}|| \cdot ||\vec{B}||}$$


Значення Sim в $[0, 1]$, де 1 означає ідентичність, 0 – повну відмінність

❑ **Обґрунтування вибору методу:** TF-IDF з косинусною подібністю забезпечує оптимальний баланс між точністю, інтерпретованістю результатів, обчислювальною ефективністю та стійкістю до лексичних варіацій

07

Алгоритм обробки даних

NLP Pipeline



08

Метод автоматичної верифікації



Крок 1: Часове вікно

Пошук потенційних першоджерел обмежується часовим інтервалом $[T_{\{tg\}} - |\Delta t|, T_{\{tg\}} + |\Delta t|]$, де $T_{\{tg\}}$ – час публікації в Telegram, $|\Delta t|$ – допустиме відхилення (зазвичай +24 години)



Крок 2: Пошук відповідника

Обчислення косинусної подібності між векторним представленням Telegram-поста та всіх кандидатів з перевірених джерел. Вибір новини з максимальним значенням $Score_{\{max\}}$



Крок 3: Прийняття рішення

Застосування порогового значення $|\tau|$ (емпірично встановлене на рівні 0.6):

• Якщо $Score_{\{max\}} \geq |\tau| \rightarrow$ **Verified** (верифіковано)

• Якщо $Score_{\{max\}} < |\tau| \rightarrow$ **Unverified** (неверифіковано)

Цей триетапний процес забезпечує ефективну фільтрацію недостовірного контенту при збереженні високої пропускної здатності системи.

09

Архітектура системи



Analysis & Verification

Модуль векторизації (TF-IDF Vectorizer) та верифікатор для автоматичної перевірки достовірності контенту



Data Storage

MongoDB з колекціями telegram_posts (необроблені дані) та trusted_news (верифіковані першоджерела)



Data Processing

NLP Preprocessor для очищення, токенизації, лематизації та підготовки текстів до аналізу



Data Collection

Telegram Scraper (Telethon API) та Web Crawler (BeautifulSoup/Scrapy) для автоматизованого збору даних

Модульна архітектура забезпечує масштабованість, незалежне тестування компонентів та простоту підтримки системи.

10

Висновки

Аналіз проблеми

Проаналізовано недоліки існуючих корпусів: статичність, академічність та відсутність верифікації контенту.

Розроблений метод

Розроблено метод верифікації на основі TF-IDF та Cosine Similarity для автоматичної перевірки достовірності текстів.

Архітектура системи

Спроектовано модульну архітектуру на Python + MongoDB з компонентами для збору, обробки та верифікації даних.

Практичне значення

Система дозволяє формувати динамічні верифіковані корпуси української мови, критично важливі для боротьби з дезінформацією.